

Sujet d'analyse : Les facteurs influençant les retards aériens à New York en 2013

*Analyse réalisée à partir de la base de données **nycflights13***

Présentation de la base de données

La base de données **nycflights13** contient l'ensemble des vols au départ des trois principaux aéroports de New York (JFK, LGA et EWR) durant l'année 2013. Chaque ligne correspond à un vol individuel et comprend des informations sur la compagnie aérienne, les heures de départ et d'arrivée, les retards enregistrés, la distance parcourue, la durée du vol et l'aéroport de destination.

Colonnes principales

- **year** : Année (2013)
- **month** : Mois du vol
- **day** : Jour du vol
- **dep_time** : Heure réelle de départ
- **sched_dep_time** : Heure prévue de départ
- **dep_delay** : Retard au départ (en minutes)
- **arr_time** : Heure réelle d'arrivée
- **arr_delay** : Retard à l'arrivée (en minutes)
- **carrier** : Code de la compagnie aérienne (ex : DL, UA, AA)
- **origin** : Aéroport de départ (JFK, LGA, EWR)
- **dest** : Aéroport de destination
- **air_time** : Durée du vol (minutes)
- **distance** : Distance parcourue (miles)

Objectif de l'analyse

L'objectif de cette étude est d'identifier **quand**, **où** et **pourquoi** les retards se produisent, et d'analyser les différences entre les compagnies aériennes, les mois et les aéroports de départ.

Hypothèses et visualisations proposées

Hypothèse 1 : Les retards sont plus fréquents pendant l'été et en fin de journée.

Graphiques proposés :

1. Histogramme du nombre de vols en retard par mois.
2. Boxplot des retards (*arr_delay*) par mois.
3. Courbe de tendance des retards moyens par heure de départ.
4. Heatmap mois $\times$ heure du retard moyen.

Hypothèse 2 : Certains aéroports new-yorkais sont plus touchés par les retards.

Graphiques proposés :

1. Bar chart du retard moyen par aéroport d'origine (*origin*).
2. Boxplot des retards à l'arrivée selon l'aéroport.
3. Violin plot des retards au départ selon l'aéroport.
4. Heatmap origine $\times$ destination du nombre moyen de retards.

Hypothèse 3 : Les retards au départ entraînent des retards à l'arrivée.

Graphiques proposés :

1. Nuage de points (*dep_delay* vs *arr_delay*) avec ligne de régression.
2. Courbe moyenne du retard à l'arrivée en fonction du retard au départ.
3. Jointplot de densité entre départ et arrivée.
4. Histogramme du taux de rattrapage (*arr_delay* - *dep_delay*).

Hypothèse 4 : Les compagnies n'ont pas la même performance de ponctualité.

Graphiques proposés :

1. Bar chart du retard moyen par compagnie (*carrier*).
2. Boxplot de la distribution des retards par compagnie.
3. Bar chart du nombre de vols annulés par compagnie.
4. Heatmap de corrélation entre *distance*, *air_time*, *dep_delay*, *arr_delay*.

Ce plan d'analyse servira de base à la visualisation et à l'interprétation statistique des retards aériens à New York.