


PLOT 01 :

Impact des retards au départ sur les retards à l'arrivée
Aéroports de New York - 2013



Présentation du graphique (30 secondes)

"Pour mon premier graphique réalisé avec **Matplotlib**, j'ai créé un **nuage de points avec régression linéaire** pour analyser la relation entre les retards au départ et les retards à l'arrivée.

Chaque point bleu représente un vol, avec en abscisse le retard au départ en minutes, et en ordonnée le retard à l'arrivée. La ligne rouge représente la **droite de régression linéaire** qui modélise cette relation."

Interprétation des résultats (40 secondes)

"Les résultats sont très clairs : il existe une **forte corrélation positive** entre les deux variables, avec un **coefficient de corrélation de 0.92** et un **R^2 de 0.84**. Cela signifie que **84% de la variance des retards à l'arrivée est expliquée par les retards au départ**.

La pente de 1.01 nous indique que **chaque minute de retard au départ entraîne environ 1 minute de retard à l'arrivée**. Le p-value inférieur à 0.001 confirme que cette relation est **statistiquement très significative**.

On observe également quelques points dispersés au-dessus de la ligne, ce qui représente des vols où les retards se sont aggravés, et quelques points en-dessous, où les pilotes ont réussi à rattraper du temps en vol."

Explication du code (20 secondes)

"Au niveau du code, j'ai d'abord **nettoyé les données** en supprimant les valeurs manquantes avec `dropna()`. Ensuite, j'ai utilisé la fonction **`stats.linregress`** de la bibliothèque SciPy pour calculer la régression linéaire et obtenir tous les coefficients statistiques.

Pour la visualisation, j'ai utilisé **`scatter`** pour le nuage de points avec une transparence de 0.3 pour gérer la superposition, puis **`plot`** pour tracer la ligne de régression. J'ai ajouté un encadré avec les statistiques clés pour faciliter l'interprétation."

Conclusion (10 secondes)

"Ce graphique confirme donc clairement notre hypothèse : **les retards au départ entraînent bien des retards à l'arrivée**, avec une relation presque proportionnelle de 1 pour 1."

Questions probables de l'enseignant

Q1 : "Pourquoi avez-vous choisi un nuage de points ?"

"Le nuage de points est le graphique le plus adapté pour visualiser la **corrélation entre deux variables continues**. Il permet de voir à la fois la tendance générale via la régression et la dispersion des données individuelles."

Q2 : "Que représente le R^2 de 0.84 ?"

"Le R^2 de 0.84 signifie que **84% des variations des retards à l'arrivée peuvent être expliquées par les retards au départ**. Les 16% restants sont dus à d'autres facteurs comme les conditions météo, le trafic aérien, ou la capacité des pilotes à rattraper du temps."

Q3 : "Pourquoi certains points sont loin de la ligne ?"

"Ce sont des **cas exceptionnels**. Les points au-dessus de la ligne représentent des vols où le retard s'est aggravé (problèmes supplémentaires en vol, congestion à l'arrivée). Les points en-dessous sont des vols où les pilotes ont réussi à rattraper une partie du retard grâce à des vents favorables ou une optimisation de trajectoire."

Q4 : "Avez-vous filtré les données ?"


"J'ai seulement supprimé les valeurs manquantes avec `dropna()`, mais j'ai **gardé toutes les observations**, y compris les retards extrêmes, pour avoir une analyse complète et non biaisée."

Q5 : "Pourquoi avez-vous gardé les valeurs négatives ?"

"Les valeurs négatives représentent les vols partis ou arrivés **en avance**, ce qui est un phénomène réel et fréquent dans l'aviation. Les garder permet d'avoir une analyse complète : on voit que la relation linéaire fonctionne dans **les deux sens** - si un vol part en avance, il a tendance à arriver en avance aussi. Enlever ces données aurait biaisé mon analyse en ne montrant qu'une partie de la réalité."

PLOT 02 :

Distribution des retards à l'arrivée selon le retard au départ
Aéroports de New York - 2013



Présentation du graphique (30 secondes)

"Pour mon deuxième graphique, réalisé avec **Seaborn**, j'ai créé un **violin plot** qui montre la distribution des retards à l'arrivée pour les vols partis en retard.

J'ai catégorisé les retards au départ en **5 tranches** : de 0 à 10 minutes, 10 à 20, 20 à 30, 30 à 50, et plus de 50 minutes. Chaque 'violin' représente la forme complète de la distribution des retards à l'arrivée pour cette catégorie.

La **ligne rouge en pointillés** représente le seuil zéro : au-dessus, le vol arrive en retard ; en-dessous, il a réussi à rattraper son retard et arrive en avance."

Interprétation des résultats (40 secondes)

Retard au départ	% rattrapages réussis	Interprétation
------------------	-----------------------	----------------

0-10 min	56.4%	● Plus de la moitié rattrapent complètement
10-20 min	27.7%	● Environ 1 vol sur 4 rattrape
20-30 min	10.3%	● Rattrapage difficile mais possible
30-50 min	2.5%	● Rattrapage très rare
50+ min	0.1%	● Rattrapage quasi impossible

Version 1 :

"Ce graphique révèle trois points essentiels :

Premièrement, la translation progressive des distributions vers le haut confirme que les retards au départ entraînent des retards à l'arrivée : **74.1% des vols partis en retard arrivent en retard**.

Deuxièmement, l'analyse par catégorie montre un phénomène remarquable : **56% des petits retards (0-10 min) sont rattrapés**, mais cette capacité s'effondre au-delà de 20 minutes pour devenir quasi nulle après 50 minutes. Il existe donc un **seuil critique** déterminant les chances de rattrapage.

Troisièmement, la largeur croissante des violons illustre une **variabilité qui explose** pour les gros retards : certains vols aggravent considérablement leur situation, d'autres limitent les dégâts."

Version 2 :

"Ce violin plot révèle **trois phénomènes majeurs** qui valident notre hypothèse :

Premier constat : On observe une **translation progressive des distributions vers le haut**. Plus le retard au départ est important, plus la médiane des retards à l'arrivée augmente. Cela confirme directement que **les retards au départ entraînent des retards à l'arrivée**.

Deuxième observation : Mes calculs montrent que **74.1% des vols partis en retard arrivent effectivement en retard**, validant notre hypothèse. Cependant, on observe qu'une portion de chaque violon se situe **sous la ligne rouge** - particulièrement pour les petits retards - ce qui représente les **25.9% de vols qui rattrapent complètement**.

L'analyse par catégorie révèle un pattern frappant : pour les retards de 0 à 10 minutes, **56.4% des vols rattrapent et arrivent en avance** ! Cette capacité chute drastiquement : **27.7%** pour 10-20 minutes, **10.3%** pour 20-30 minutes, et quasiment **0%** au-delà de 50 minutes. Il existe donc un **seuil critique autour de 20 minutes** : en dessous, le rattrapage reste possible ; au-delà, il devient exceptionnel.

Troisième élément : La **largeur croissante des violons** indique une variabilité qui augmente avec le retard initial. Pour les retards de plus de 50 minutes, certains vols accumulent jusqu'à 300 minutes de retard supplémentaire, tandis que d'autres parviennent à limiter l'aggravation, créant cette dispersion importante."

Version 3 :

Ce violin plot révèle trois dimensions de notre hypothèse. **Premièrement**, la translation progressive des distributions vers le haut confirme que 74.1% des vols partis en retard arrivent en retard. **Deuxièmement**, l'analyse par catégorie dévoile un seuil critique : 56% des petits retards de 0-10 minutes sont rattrapés, mais

cette capacité s'effondre à 28%, puis 10%, pour devenir quasi nulle au-delà de 50 minutes. Il existe donc une fenêtre de 20 minutes où le rattrapage reste possible. **Troisièmement**, la largeur croissante des violons illustre une variabilité explosive pour les gros retards : certains vols accumulent plusieurs heures supplémentaires, créant cette grande dispersion visible sur le dernier violon.

Explication du code (30 secondes)

"Au niveau du code, j'ai d'abord filtré les données pour ne garder que les vols avec un retard au départ positif : `df[df['dep_delay'] > 0]`, ce qui correspond directement à notre hypothèse.

J'ai ensuite utilisé `pd.cut()` pour créer les catégories de retards, puis `sns.violinplot()` pour générer la visualisation. Le paramètre `inner='quartile'` affiche les lignes blanches à l'intérieur qui représentent les quartiles de la distribution.

J'ai ajouté la ligne horizontale rouge avec `ax.axhline()` pour marquer visuellement le seuil entre retard et avance à l'arrivée."

Conclusion (10 secondes)

"En conclusion, ce graphique valide clairement notre hypothèse : **74.1% des vols partis en retard arrivent en retard**. Mais il révèle aussi une information cruciale : **les petits retards peuvent souvent être rattrapés** (56% de réussite pour 0-10 min), alors que **les gros retards sont irréversibles** (0.1% de réussite au-delà de 50 min). Il existe donc un **seuil critique** autour de 20 minutes qui détermine les chances de rattrapage."

RÉPONSES AUX QUESTIONS AVEC VOS STATS

Q1 : "Quelle proportion de vols rattrape son retard ?"

"Globalement, **25.9%** des vols partis en retard arrivent finalement en avance, soit environ 1 vol sur 4. Mais ce taux varie énormément selon le retard initial : **56.4%** pour les retards de 0-10 minutes - c'est énorme, plus d'un vol sur deux ! - mais seulement **0.1%** pour les retards de plus de 50 minutes, soit pratiquement aucun.

On voit donc qu'il y a une vraie **fenêtre d'opportunité** pour les petits retards, mais au-delà de 20-30 minutes, le rattrapage devient extrêmement difficile."

Q2 : "Pourquoi certains vols rattrapent et d'autres non ?"

"Plusieurs facteurs peuvent expliquer ces rattrapages :

- **Vents favorables** en altitude (vents arrière)
- **Optimisation de la trajectoire** par les contrôleurs aériens
- **Vitesse de croisière augmentée** par les pilotes quand c'est possible
- **Espace aérien moins congestionné** à l'arrivée

Pour les petits retards (0-10 min), ces ajustements suffisent dans plus de la moitié des cas. Mais pour les gros retards (50+ min), même tous ces facteurs combinés ne permettent pas de compenser complètement."


Q3 : "Que représente le seuil de 20 minutes ?"

"Le **seuil de 20 minutes** apparaît comme un point critique :

- En dessous : le rattrapage reste possible (56% puis 28% de réussite)
- Au-dessus : le rattrapage devient exceptionnel (10% puis 2.5%)

Cela correspond probablement aux **marges opérationnelles** des compagnies : les pilotes ont suffisamment de marge de manœuvre pour compenser 10-15 minutes, mais au-delà, les contraintes deviennent trop importantes (carburant, horaires des équipages, créneaux d'atterrissage)."

PLOT 03 :



PRÉSENTATION DU GRAPHIQUE (30 secondes)

"Pour mon troisième et dernier graphique, réalisé avec **GeoPandas**, j'ai créé une **carte géographique comparative** des trois aéroports de New York, centrée sur leur **capacité à rattraper les retards en vol**.

Chaque point circulaire représente un aéroport, et la **couleur indique le rattrapage moyen en minutes** : le vert foncé signifie un bon rattrapage, tandis que l'orange-rouge indique un rattrapage plus faible. Les encadrés détaillent **cinq métriques clés** pour chaque aéroport : la corrélation entre retards départ et arrivée, le rattrapage moyen en minutes, le pourcentage de vols rattrapant totalement leur retard, ainsi que les retards moyens au départ et à l'arrivée."

INTERPRÉTATION DES RÉSULTATS (50 secondes)

"Cette carte révèle trois observations majeures :

- **Premièrement**, les trois aéroports montrent des **corrélations très élevées** - 0.936 pour JFK, 0.940 pour LGA, et 0.943 pour EWR - ce qui confirme de manière robuste que notre hypothèse est valide **quel que soit l'aéroport de départ** : les retards au départ entraînent systématiquement des retards à l'arrivée.
- **Deuxièmement**, malgré cette tendance commune, on observe des **différences opérationnelles significatives** dans la capacité de rattrapage. **JFK** se distingue avec le meilleur rattrapage moyen de **5.5 minutes**, représenté par sa couleur vert foncé. **EWR** suit de près avec **5.0 minutes** en vert clair. En revanche, **LaGuardia** affiche seulement **3.4 minutes**, visible par sa couleur orange-rouge, soit presque **40% de moins** que JFK.
- **Troisièmement**, cette différence se reflète aussi dans les taux de rattrapage total : **27.5%** des vols de JFK rattrapent complètement leur retard contre seulement **22.6%** pour LaGuardia. Ces écarts peuvent s'expliquer par plusieurs facteurs : des types de vols différents - LaGuardia dessert principalement des vols domestiques courts, tandis que JFK et EWR opèrent plus de vols long-courriers qui ont davantage de temps pour compenser - ou des pratiques opérationnelles spécifiques à chaque aéroport."

3. EXPLICATION DU CODE (20 secondes)

"Au niveau du code, j'ai utilisé **GeoPandas** pour créer un GeoDataFrame avec les coordonnées GPS des trois aéroports. Pour chaque aéroport, j'ai calculé cinq métriques via `groupby()` : la corrélation, le rattrapage moyen calculé comme la différence entre retard au départ et à l'arrivée, le pourcentage de rattrapages totaux, et les retards moyens.

J'ai ensuite superposé ces données sur une carte des États-Unis avec un zoom sur la région new-yorkaise, en utilisant une palette **RdYlGn** - rouge-jaune-vert - avec une échelle ajustée de 3 à 6 minutes pour maximiser le contraste visuel entre les aéroports."

4. CONCLUSION (10 secondes)

"En conclusion, cette carte valide notre hypothèse de manière universelle pour les trois aéroports, tout en révélant une découverte intéressante : **JFK et EWR gèrent significativement mieux les retards** avec une capacité de rattrapage supérieure de 50 à 60% par rapport à LaGuardia."

RÉPONSES AUX QUESTIONS PROBABLES

Q1 : "Pourquoi JFK et EWR rattrapent mieux que LGA ?"

"Plusieurs facteurs peuvent expliquer cette différence :

- **Le type de vols** : JFK et EWR opèrent davantage de vols internationaux et long-courriers, qui ont plus de temps en vol pour ajuster leur vitesse et rattraper du retard. LaGuardia se concentre principalement sur les vols domestiques courts où les marges de manœuvre sont réduites.

-La distance des destinations : Sur un vol de 5-6 heures vers l'Europe ou la Californie, rattraper 5-10 minutes est plus facile que sur un vol de 1 heure vers Boston.

-Les types d'avions : JFK et EWR utilisent plus de gros porteurs qui peuvent augmenter leur vitesse de croisière, tandis que LaGuardia accueille principalement des avions régionaux plus petits.

Cependant, je ne peux pas analyser plus en détail les destinations car c'est l'objet de l'hypothèse 2 traitée par un autre membre du groupe."

Q2 : "2 minutes de différence, est-ce vraiment significatif ?"

"Absolument. Bien que 2 minutes puissent sembler faibles individuellement, à l'échelle de **milliers de vols par an**, cela représente :

- Des **centaines d'heures** économisées au total
- Une meilleure **expérience passager**
- Moins de **vols en cascade de retards**
- Une **optimisation des créneaux d'atterrissage**

De plus, cette différence est une **moyenne** : certains vols individuels à JFK peuvent rattraper 15-20 minutes, ce qui fait une vraie différence pour les passagers ayant des correspondances."

Q3 : "Pourquoi utiliser GeoPandas pour seulement 3 points ?"

"Excellente question. Même avec 3 points, GeoPandas apporte une **dimension spatiale** essentielle à l'analyse :

Premièrement, cela permet de visualiser la **proximité géographique** des trois aéroports : ils sont dans la même région métropolitaine, ce qui rend leurs différences opérationnelles d'autant plus intéressantes.

Deuxièmement, cela contextualise l'analyse dans un **cadre géographique réel** plutôt qu'un simple graphique en barres abstrait.

Troisièmement, cette approche est **extensible** : si on voulait comparer avec d'autres hubs américains comme Chicago ou Atlanta, la méthodologie est déjà en place.

Enfin, GeoPandas est l'outil professionnel standard pour les analyses spatiales en data science, donc c'était pertinent de l'utiliser pour ce projet."

Q4 : "Comment ce plot s'intègre-t-il avec vos deux premiers graphiques ?"

"Les trois plots racontent une **histoire cohérente et progressive** :

Le Plot 1 avec Matplotlib établit la **relation globale** : il y a une forte corrélation linéaire ($R^2=0.84$) entre retards au départ et à l'arrivée, validant l'hypothèse de base.

Le Plot 2 avec Seaborn approfondit en montrant la **distribution détaillée** : 74% des vols partis en retard arrivent en retard, avec un seuil critique à 20 minutes et des capacités de rattrapage qui s'effondrent au-delà.

Le Plot 3 avec GeoPandas ajoute une **dimension géographique comparative** : cette relation existe dans les trois aéroports de New York, mais avec des capacités opérationnelles différentes. JFK et EWR montrent une meilleure performance.

Ensemble, ils offrent une vision **complète** : tendance générale, variabilité statistique, et variations géographiques."

Q5 : "Quelle est la corrélation entre la taille de l'aéroport et le rattrapage ?"

"C'est une observation intéressante. On pourrait penser qu'un gros aéroport comme JFK rattraperait moins à cause de la congestion, mais c'est l'inverse. Cela suggère que **la taille et les infrastructures** jouent en faveur du rattrapage :

- Plus de ressources opérationnelles
- Meilleure coordination avec le contrôle aérien
- Plus d'expérience dans la gestion des retards

LaGuardia, bien que très fréquenté, est physiquement plus petit et opère principalement des vols courts, ce qui limite ses marges de manœuvre."

Chiffres importants à mémoriser :

-  Corrélations : **0.936, 0.940, 0.943** (toutes très élevées)
-  Rattrapages moyens : **5.5 min (JFK), 5.0 min (EWR), 3.4 min (LGA)**
-  % rattrapage total : **27.5% (JFK), 26.8% (EWR), 22.6% (LGA)**
-  Différence : JFK rattrape **60% de plus** que LGA (5.5 vs 3.4)

Message principal :

"L'hypothèse est validée universellement, mais avec des nuances opérationnelles : JFK et EWR sont plus performants."